— PIERWSZY MODEL

Regresja liniowa

Prosty model · analityczna metoda uczenia · fundament ML

KAMIL JĘDRYCZEK

• TRYB PREZENTACJI · P ABY WYŁĄCZYĆ

PLAN NA DZIŚ

Pełny pipeline ML na najprostszym przykładzie

01 **Dane**
Ceny mieszkań · EDA

02 **Model liniowy**
y = ax + b, zapis wektorowy, parametry

03 **Uczenie = optymalizacja**
MSE, intuicja minimum, gradient descent

04 **Wzór analityczny**
Wyzerowanie pochodnej · normal equations

05 **Reprezentacja graficzna**
Linia w 2D · płaszczyzna w 3D

06 **Overfitting**
Regresja wielomianowa, pierwsza pułapka ML

— CZĘŚĆ 1

01. Dane o mieszkaniach

Cechy sprzedawanych mieszkań i domów — dane jako punkt wyjścia do każdego modelu.

— DATASET

Mieszkania & domy w hrabstwie King

REKORDY
~21k
transakcji nieruchomości

CECHY
19
kolumn opisujących każdą

TARGET
price
cena sprzedaży w USD

ZADANIE
regresja
przewidywanie liczby

- sqft_living
- bedrooms
- bathrooms
- floors
- waterfront
- view
- condition
- grade
- yr_built
- zipcode
- lat / long

+ kilka innych

— KROK ZERO

Zanim cokolwiek zamodelujemy — analizujemy (EDA — Exploratory Data Analysis)

- **Histogramy niektórych cech**
  Rozkład, skewness, ogony
- **Korelacje**
  Co jest skorelowane z ceną, co z czym
- **Braki danych**
  NaN-y, puste pola, niestandardowe wartości
- **Outliery**
  Mieszkanie z 33 sypialniami to dane czy błąd?

RULE OF THUMB

80% pracy w ML to data engineering.

Modele to ostatnie 20%. Im lepiej rozumiesz dane, tym lepszy model — i mniej godzin debugowania.

— CZĘŚĆ 2

02. Model liniowy

Funkcja, którą znamy ze szkoły — i jej skalowanie na wiele wymiarów.

— FUNKCJA LINIOWA

Znana ze szkoły

$$\hat{y} = a \cdot x + b$$

a — **Nachylenie**
o ile rośnie y, gdy x rośnie o 1

b — **Przesunięcie**
wartość y, gdy x = 0 (bias)

ŷ — **Predykcja modelu**
to, co model myśli — nie prawdziwe y

Cała „wiedza" modelu siedzi w parametrach a i b.

• TRYB PREZENTACJI · P ABY WYŁĄCZYĆ

— UOGÓLNIENIE

Więcej cech?
to samo, w notacji macierzowej

$$\hat{y} = w^T x + b$$

$$\hat{y} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^T \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} + \begin{bmatrix} b \end{bmatrix}$$

w (wektor wag)

jedna liczba na każdą cechę — czyli „ile waży" sqft, ile bedrooms...

x (wektor cech)

wartości cech jednego rekordu — np. jednego mieszkania

$w^T x$ = iloczyn skalarny

suma wag pomnożonych przez cechy — to samo, co wcześniej, w większym wymiarze

— CZĘŚĆ 3

03. Uczenie = optymalizacja

Skąd model bierze parametry? Z danych — minimalizując błąd.

— FUNKCJA KOSZTU

Mean Squared Error

średni błąd kwadratowy

$$J = \frac{1}{n} \sum_{i=1}^{n} \left[\hat{y}_i - y_i \right]^2$$

Dla każdego rekordu liczymy:

różnicę między tym, co model przewiduje ($\hat{y}$), a rzeczywistą wartością (y).

Podnosimy do kwadratu:

żeby błędy w obie strony nie kasowały się oraz aby duże błędy bolały bardziej niż małe.

Uśredniamy:

jedna liczba — jak bardzo model się myli na całym zbiorze.

Minimalizacja MSE = uczenie modelu. Tyle.

— INTUICJA

Gdzie jest minimum?

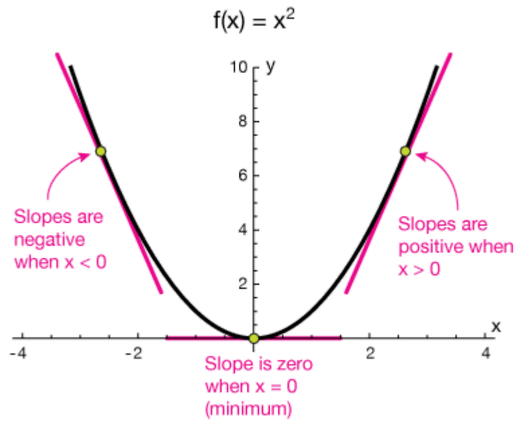

Pochodna = nachylenie

styczna do krzywej w danym punkcie.

W minimum — pochodna = 0

styczna jest pozioma, funkcja przestaje maleć.

★ KLUCZOWA INTUICJA

To jest sercem ML

cała optymalizacja sieci neuronowych — to ten sam pomysł, tylko w **milionach wymiarów**.

• TRYB PREZENTACJI · P ABY WYŁĄCZYĆ

— METODA NUMERYCZNA

Gradient descent

schodzimy w dół po gradiencie

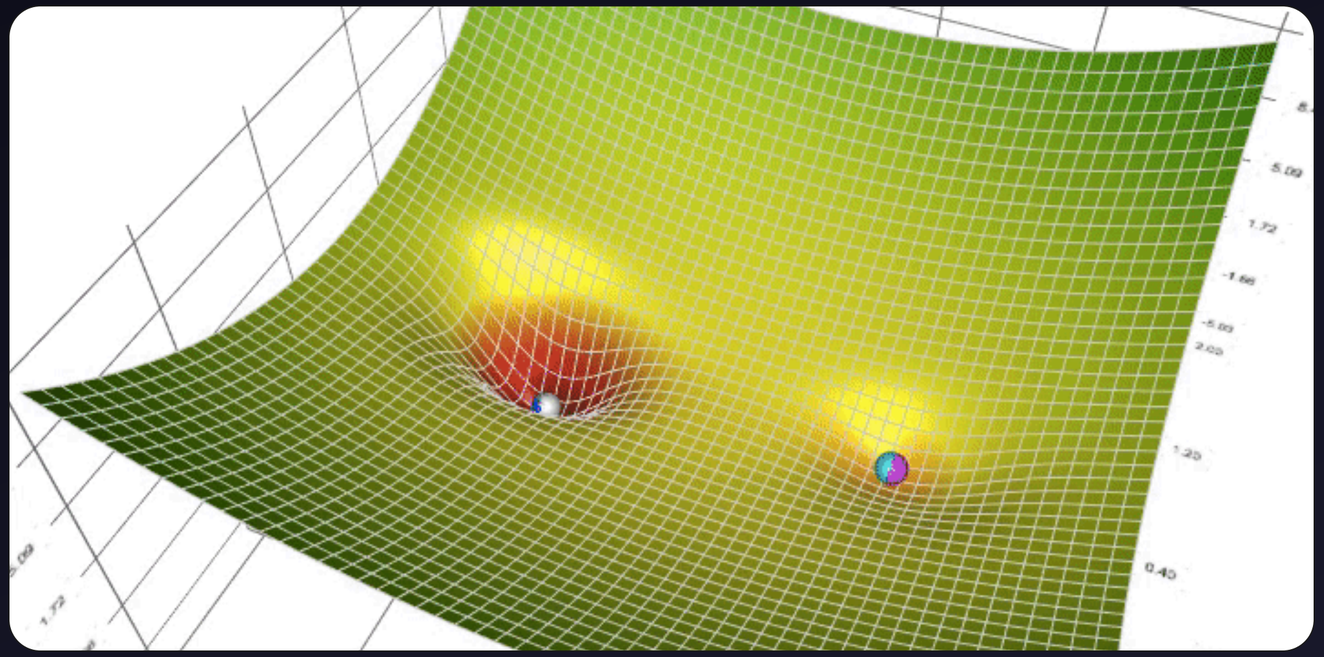

Krok po kroku

aktualizujemy parametry w kierunku, w którym MSE maleje.

Hiperparametr: learning rate

jak duży krok robimy. Za duży — przeskakujemy minimum. Za mały — nigdy nie dojdziemy.

Uniwersalna metoda

tak uczy się każda sieć neuronowa — od regresji po LLM. Tu pokazujemy intuicję.

— INTUICJA W 1D

W którą stronę iść?

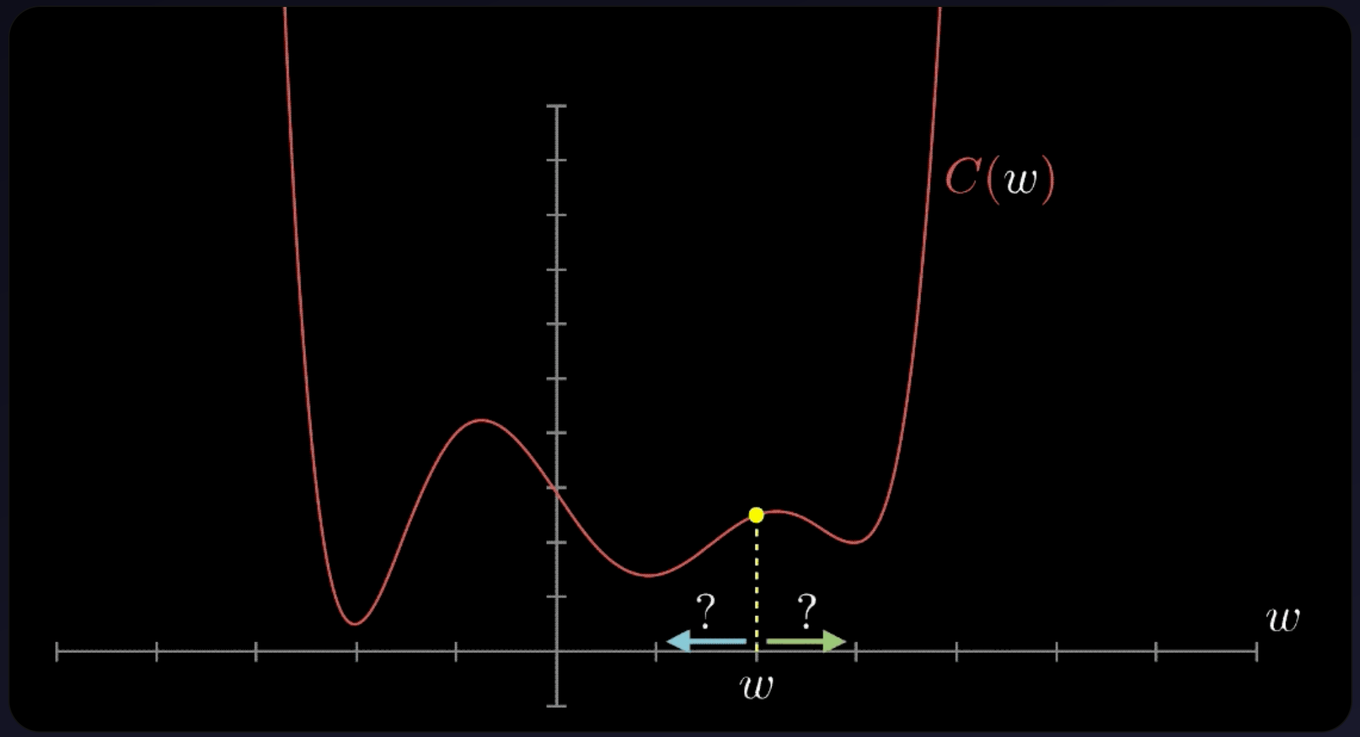

Lokalna decyzja

w każdym punkcie patrzymy tylko na **znak pochodnej** — to mówi nam, w którą stronę funkcja maleje.

Pochodna ujemna → idziemy w prawo

funkcja maleje, więc zwiększamy `w`.

Pochodna dodatnia → idziemy w lewo

funkcja rośnie, więc zmniejszamy `w`.

Uwaga — możemy utknąć w lokalnym minimum. Funkcja straty regresji liniowej jest wypukła, więc tu tego problemu nie mamy. W sieciach neuronowych — bywa.

— LUKSUS REGRESJI LINIOWEJ

Gotowy wzór

Wyzerowanie pochodnej daje równania, z których **analitycznie** wyliczamy parametry — bez iteracji, bez learning rate. Taka sytuacja jest tylko dla regresji liniowej!

DLA y = ax + b

$$a_1 = \frac{\sum(x-\bar{x})(y-\bar{y})}{\sum(x-\bar{x})^2} = \frac{\sum(xy) - n\bar{x}\bar{y}}{\sum x^2 - n\bar{x}\bar{x}}$$

$$a_0 = \bar{y} - a_1\bar{x}$$

ZAPIS MACIERZOWY

$$w = (X^T X)^{-1} X^T Y$$

normal equations

★ KROK PO KROKU — WYPROWADZENIE

PL Po polsku ↗
notacja zwykła

EN Po angielsku ↗
najprościej, notacja zwykła

EN Po angielsku ↗
notacja macierzowa

• TRYB PREZENTACJI · P ABY WYŁĄCZYĆ

— WYNIK · 1 CECHA

Cena vs metraż

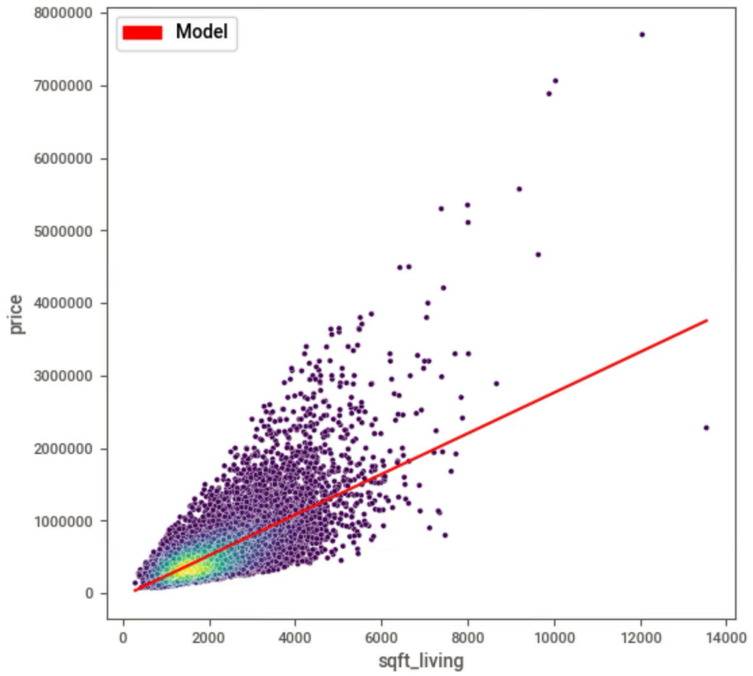

Model
linia, którą znaleźliśmy

Dane rzeczywiste
~21k transakcji

Linia łapie ogólny trend, ale **nie tłumaczy** outlierów ani lokalności (zipcode, lokalizacja).

— WYNIK · 2 CECHY

Linia → płaszczyzna

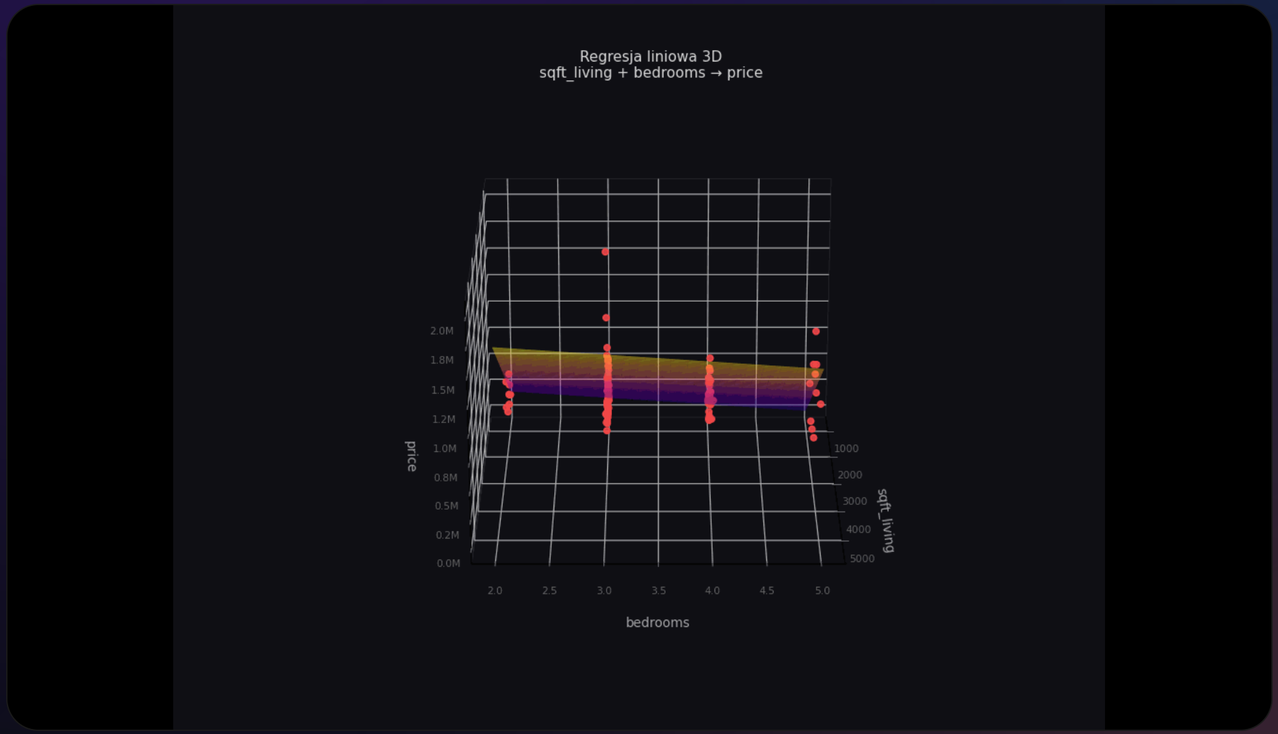

2 cechy → płaszczyzna

model wciąż liniowy, ale w 3D to już płaska kartka, nie linia.

N cech → hiperpłaszczyzna

w dowolnym wymiarze. Tylko że w 4D+ już nie narysujemy — matematyka jest ta sama.

Skalowalność — wzór macierzowy
$w = (X^T X)^{-1} X^T Y$ działa dla dowolnej liczby cech.

• TRYB PREZENTACJI · P ABY WYŁĄCZYĆ

— PIERWSZA PUŁAPKA

Regresja wielomianowa & overfitting

$$\hat{y} = a_k \cdot x^k + \ldots + a_2 \cdot x^2 + a_1 \cdot x + a_0$$

Dodajemy potęgi x

x^2 , x^3, x^4... Model coraz bardziej elastyczny — może wić się jak chce. Ma to wady i zalety — jeśli za dużo tych potęg to model zacznie predykować bezsensowne dane (zobacz gif) →

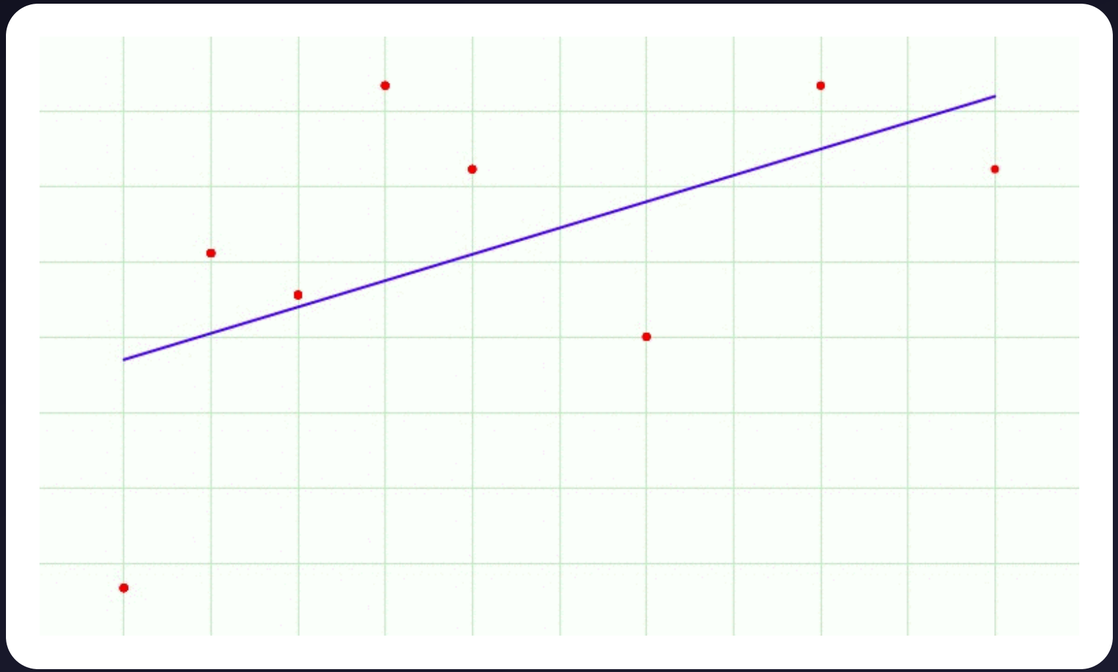

Overfitting — model „przytula się" do danych uczących. Świetnie zapamiętuje, ale nie potrafi **generalizować.**

— PODSUMOWANIE

Cztery rzeczy do zapamiętania

01 Prosty model regresji

$\hat{y} = w^T x + b$ · funkcja liniowa wielu cech.

02 Analitycznie wyznaczane

Wzór z wyzerowania pochodnej — bez iteracji.

03 Parametry = wiedza modelu

Cała informacja siedzi w **a** i **b** lub **w**. Nic poza tym.

04 Overfitting

Pierwsza pułapka ML — wracamy do niej w każdym kursie.

— SPRAWDŹMY WIEDZĘ

Pytania podsumowujące

01 Jakie były trzy rodzaje uczenia maszynowego?

z nadzorem · bez nadzoru · ze wzmocnieniem

02 Jakiej funkcji kosztu używaliśmy w regresji?

Błąd średniokwadratowy (MSE)

03 W jaki sposób analitycznie wyznaczyliśmy parametry regresji liniowej?

Przyrównanie pochodnej funkcji kosztu do 0

04 Czym jest overfitting?

Zbyt dobre dopasowanie modelu do danych uczących — predykcja na danych testowych staje się niemiarodajna.

— KONIEC WYKŁADU

Pytania?

Dziękuję za uwagę.

KAMIL JĘDRYCZEK · REGRESJA LINIOWA

● TRYB PREZENTACJI · P ABY WYŁĄCZYĆ